Filippo Lollato

filippo@lollato.dev • lollato.dev • github.com/xupremix • Trento / Bassano del Grappa, Italia

Data di Nascita: 29/07/2003 • Luogo di Nascita: Bassano del Grappa (VI), Italia

Istruzione

Laurea Magistrale in Artificial Intelligence Systems *2024 - Presente*
Università di Trento *Trento, Italia*

- **Aree di Specializzazione**: Integrazione di Sistemi AI, Ottimizzazione e Fine-Tuning di Modelli, Sistemi Multi-Agente, Deep Learning, Architetture Software Scalabili.
- **Obiettivo**: Ricerca attiva di opportunità di tirocinio per tesi magistrale in azienda/laboratorio AI d'eccellenza per integrare e ottimizzare modelli AI in servizi e sistemi reali.

Laurea Triennale in Informatica *2021 - 2024*
Università di Trento *Trento, Italia*

- **Tesi di Laurea**: *Kindle: A Machine Learning Framework for Compile-Time Invariant and Dimensionality Safety* (Relatore: Prof. Marco Patrignani).
- **Corsi Principali**: Algoritmi e Strutture Dati, Programmazione di Sistema, Architettura degli Elaboratori, Sistemi Operativi, Calcolo delle Probabilità e Statistica.

Esperienza

Ricercatore & Studente Magistrale in AI Systems *2024 - Presente*
Università di Trento *Trento, Italia*

- Ricerca e sviluppo nell'ottimizzazione e fine-tuning di modelli, apprendimento multi-task e integrazione di intelligenza artificiale in sistemi e servizi software reali.
- Progettazione di architetture che collegano LLM e modelli specialistici a backend di produzione tramite chiamate strutturate (tool-use), orchestrazione di stato e pipeline a eventi.
- Lead systems architect su framework multi-agente ad alta affidabilità e sicurezza a tempo di compilazione per reti neurali.
- Preparazione per tesi magistrale in azienda su ottimizzazione di modelli, integrazione di servizi AI o architetture per agenti.

Tutor Universitario / Assistente alla Didattica in Algoritmi *2024 - Presente*
Università di Trento *Trento, Italia*

- Selezionato tramite bando dipartimentale per l'insegnamento ad oltre 50 studenti triennali in Algoritmi, Strutture Dati e programmazione di sistema in C/C++.
- Conduzione di sessioni settimanali di problem solving, revisione del codice e laboratori di debugging per implementazioni efficienti e performanti.

Progetti Selezionati

incin: Framework di Deep Learning Type-Safe *Rust, CUDA, Const Generics*
Framework backend-agnostic per reti neurali con verifica a tempo di compilazione.

- Progettazione di un motore deep learning ad alte prestazioni in Rust con tipi affini e const generics per garantire compatibilità di shape e rango a tempo di compilazione con zero overhead a runtime.

- Implementazione di grafo di differenziazione automatica, operatori Conv2d con verifica di parità dei gradienti CUDA, checkpointing e trasformazioni modulari.

ASA Autobots: Sistema Multi-Agente Ibrido (LLM + Simbolico) *Node.js, PDDL, BDI, Integrazione LLM Locale*
Piattaforma cooperativa per compiti logistici che integra ragionamento LLM e pianificazione simbolica.

- Architettura basata sulla collaborazione real-time tra agenti autonomi BDI, integrazione di LLM locali (Llama 3.3 70B) e pianificatore simbolico PDDL per compiti logistici.
- Integrazione di chiamate strutturate JSON-RPC / tool use, gestione resiliente degli errori e test coverage del ~91.5% su un'architettura a 3 livelli.

signal_image_video: Tracciamento 3D Multi-Oggetto con Sensor Fusion *Python, PyTorch, LiDAR, EKF, KITTI*
Sistema di tracciamento 3D con fusione camera-LiDAR valutato sul benchmark KITTI.

- Sviluppo di una pipeline di fusione sensoriale 3D LiDAR-camera combinando filtro di Kalman CTRV-EKF e algoritmo Ungherese per l'assegnazione bi-partita.
- Valutazione sul benchmark di guida autonoma KITTI con netta riduzione dell'RMSE rispetto alla baseline lineare.

NLU: Intent Classification & Slot Filling Congiunto *Python, PyTorch, Transformers, BERT*
Pipeline end-to-end di Natural Language Understanding sul dataset ATIS.

- Pipeline di training costruita da zero, fine-tuning di modelli transformer (BERT) con teste congiunte di intent classification e sequence labeling.
- Raggiunta un'accuratezza dell'intent pari a 0.9765 ed elevato F1 score per il rilevamento degli slot.

evolcpp: Motore di Neuroevoluzione in C++20 *C++20, Template Metaprogramming, CMake*
Porting ad alte prestazioni delle astrazioni neurali con type safety a tempo di compilazione.

- Implementazione delle astrazioni tensoriali con template metaprogramming in C++20 per garantire shape safety a tempo di compilazione senza overhead di memoria dinamica.

Competenze Tecniche e Certificazioni

Ottimizzazione & Tuning di Modelli: Fine-Tuning (LoRA, QLoRA), Distillazione di Modelli, Quantizzazione (NVFP4, GGUF, AWQ, FP8), Allineamento (DPO, RLHF), Multi-Task Learning, HuggingFace

Integrazione di Sistemi AI & Servizi: Sistemi Multi-Agente (BDI, PDDL), Tool Use & Function Calling, LLM Orchestration, Model Serving (vLLM, Ollama, ONNX Runtime), API Streaming (SSE, WebSocket), RAG

Deep Learning & Percezione: PyTorch, Architetture Transformer (BERT), Modelli di Diffusione, Sensor Fusion 3D LiDAR-Camera, Filtri di Kalman (CTRV-EKF), CUDA C/C++

Linguaggi & Sistemi Backend: Rust, C++ (C++20), Python, TypeScript, Linux (Debian/Ubuntu), Docker, CMake, Cargo, API REST, Axum, Node.js, Git, CI/CD

Certificazioni Linguistiche: Cambridge English: Livello C1 (Pass at Grade A, Punteggio 182) • Italiano (Madrelingua)

Autorizzo il trattamento dei miei dati personali presenti nel cv ai sensi del Decreto Legislativo 30 giugno 2003, n. 196 e del GDPR (Regolamento UE 2016/679).